Feature-engineering-baseline-model-2

March 29, 2021

```
[208]: import pandas as pd
    from matplotlib import pyplot as plt
    import seaborn as sns
    import numpy as np
    import copy

[209]: # loading data
    df_voice = pd.read_csv("./src/gender_voice_dataset.csv")
```

1 Feature engineering

1.1 Missing values

```
[210]: df_voice.isna().sum()
[210]: meanfreq
       sd
                    0
       median
                    0
       Q25
       Q75
                    0
       IQR
                    0
       skew
                    0
       kurt
                    0
       sp.ent
                    0
       sfm
       mode
       centroid
                    0
       meanfun
                    0
       minfun
                    0
                    0
       maxfun
       meandom
                    0
       mindom
       maxdom
                    0
       dfrange
       modindx
       label
       dtype: int64
```

Nie mamy żadnych brakujących wartości więc nie musimy się przejmować wypełnianiem braków.

1.2 Outliers

Aby pozbyć się wartości odstających postanowiliśmy usunąć te wartości, które znajdują się w dowolnej kolumnie dalej od średniej niż 4 odchylenia standardowe. Straciliśmy w ten sposób około 200 obserwacji ($\sim 7~\%$)

2 Usuwamy mocno skorelowane kolumny

```
[214]: c = df_voice.corr().abs()
       s = c.unstack()
       so = s.sort_values(kind="quicksort")
       so = so.loc[(so < 1) & (so > 0.8)]
       so[::-1]
[214]: dfrange
                 maxdom
                              0.999819
                 dfrange
       maxdom
                              0.999819
      meanfreq median
                              0.920930
      median
                 meanfreq
                              0.920930
                 centroid
                              0.920930
       centroid
                 median
                             0.920930
                 Q25
                              0.906848
       meanfreq
       Q25
                 meanfreq
                              0.906848
                              0.906848
                 centroid
       centroid Q25
                              0.906848
```

sp.ent	sfm	0.894434
sfm	sp.ent	0.894434
skew	kurt	0.888241
kurt	skew	0.888241
sd	sfm	0.879856
sfm	sd	0.879856
Q25	IQR	0.870892
IQR	Q25	0.870892
sp.ent	sd	0.861690
sd	sp.ent	0.861690
	IQR	0.859711
IQR	sd	0.859711
sd	Q25	0.831376
Q25	sd	0.831376
sfm	centroid	0.824912
centroid	sfm	0.824912
sfm	${\tt meanfreq}$	0.824912
${\tt meanfreq}$	sfm	0.824912
Q25	sfm	0.812022
sfm	Q25	0.812022
maxdom	meandom	0.810879
meandom	maxdom	0.810879
dfrange	meandom	0.809513
meandom	dfrange	0.809513
sp.ent	Q25	0.802479
Q25	sp.ent	0.802479
dtype: float64		

min

Bardzo dużo kolumn jest skorelowanych, więc aby uprościć nasz model usuwamy kolumny, których współczynnik skorelowania jest wyższy niż 0.8 . W przypadku decyzji, którą z kolumn usunąć, usuwaliśmy tą która była w mniejszym stopniu skorelowana z targetem.

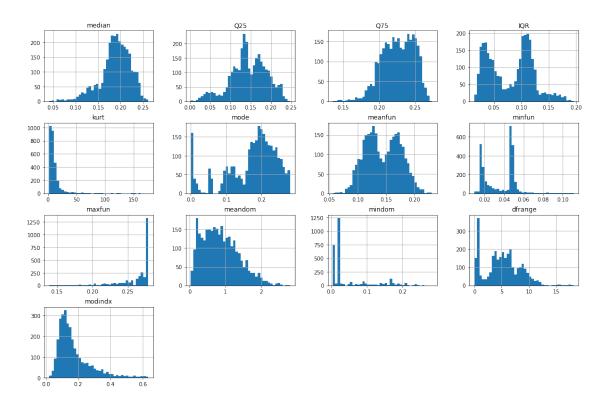
```
[215]: df_voice.drop(axis = 1,__

→columns=['maxdom', 'meanfreq', 'centroid', 'skew', "sfm", "sp.ent", "sd"], inplace

        →= True)
[216]:
       df_voice.shape
[216]: (2949, 14)
[217]:
       df_voice.describe()
[217]:
                    median
                                     Q25
                                                   Q75
                                                                 IQR
                                                                              kurt
              2949.000000
                            2949.000000
                                          2949.000000
                                                        2949.000000
                                                                      2949.000000
       count
                  0.188208
                                0.144507
                                              0.226066
                                                           0.081558
                                                                        12.200320
       mean
                  0.033759
                                0.045143
                                              0.022216
                                                           0.040448
                                                                        15.659715
       std
                  0.040976
                                0.002119
                                              0.135023
                                                           0.014922
                                                                         2.068455
```

```
25%
                 0.172308
                               0.117253
                                             0.209596
                                                           0.041830
                                                                         5.525481
       50%
                                             0.227254
                  0.191191
                               0.142745
                                                           0.090769
                                                                         8.014466
       75%
                  0.211903
                               0.176935
                                             0.244356
                                                           0.112812
                                                                        12.686097
                                             0.273469
                                                                      175.696791
       max
                  0.261224
                               0.247347
                                                           0.195527
                                meanfun
                                               minfun
                                                             maxfun
                                                                          meandom
                      mode
              2949.000000
                            2949.000000
                                          2949.000000
                                                       2949.000000
                                                                     2949.000000
       count
                                             0.036623
                                                           0.260189
       mean
                 0.172420
                               0.144361
                                                                         0.863398
                 0.071832
                               0.030800
                                             0.016271
                                                           0.027751
                                                                         0.507932
       std
       min
                  0.000000
                               0.055565
                                             0.009775
                                                           0.138889
                                                                         0.030331
       25%
                 0.130878
                               0.119456
                                             0.018735
                                                           0.253968
                                                                         0.460938
       50%
                 0.190129
                               0.142627
                                             0.046921
                                                           0.272727
                                                                         0.799267
       75%
                  0.223524
                               0.169677
                                             0.047952
                                                           0.277457
                                                                         1.200000
                  0.280000
       max
                               0.231135
                                             0.111111
                                                           0.279114
                                                                         2.805246
                   mindom
                                dfrange
                                              modindx
              2949.000000
                                          2949.000000
                            2949.000000
       count
                  0.052433
                               5.176516
                                             0.171745
       mean
       std
                  0.061858
                               3.251309
                                             0.102546
       min
                  0.004883
                               0.019531
                                             0.019881
       25%
                  0.007812
                               3.046875
                                             0.103387
       50%
                 0.023438
                               5.132812
                                             0.141026
       75%
                 0.070312
                               7.242188
                                             0.208218
                 0.281250
                              18.164062
       max
                                             0.633584
[218]: df_voice.hist(bins = 40, figsize=(18, 12))
```

plt.show()



3 Standaryzacja

Standaryzujemy dane aby były zcentrowane do zera i żeby ich wariancje były tego samego rzędu. Robimy to po to, aby żadna zmienna nie dominowała i model mógł się uczyć na wszystkich zmiennych.

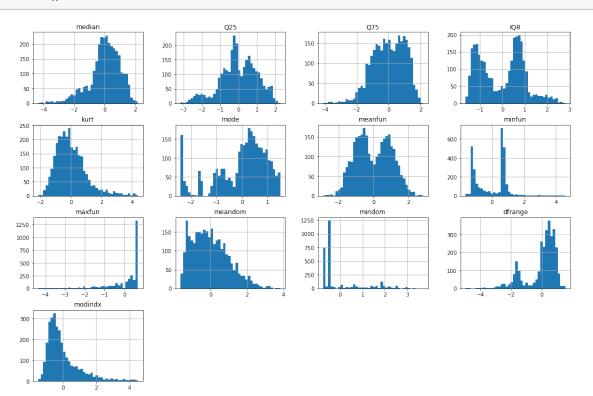
```
[261]: from sklearn import preprocessing
       scaler = preprocessing.StandardScaler().fit(df_voice.drop("label",axis=1))
       df_voice_standard = pd.DataFrame(scaler.transform(df_voice.

→drop("label",axis=1)),columns=['median','Q25','Q75','IQR','kurt','mode','meanfun','minfun',
       df_voice_standard.describe()
[261]:
                    median
                                     Q25
                                                    Q75
                                                                  IQR
                                                                                kurt
                            2.949000e+03
                                           2.949000e+03
                                                         2.949000e+03
       count
              2.949000e+03
                                                                       2.949000e+03
             -3.276833e-16 -3.469588e-16
                                           1.310733e-15
                                                         7.710196e-17 -5.204382e-16
      mean
              1.000170e+00
                            1.000170e+00
                                           1.000170e+00
                                                         1.000170e+00
                                                                       1.000170e+00
       std
             -4.362076e+00 -3.154668e+00 -4.098841e+00 -1.647735e+00 -2.146557e+00
       min
       25%
             -4.710793e-01 -6.038348e-01 -7.414738e-01 -9.823819e-01 -7.034739e-01
       50%
              8.839287e-02 -3.904454e-02
                                           5.348298e-02
                                                         2.277668e-01 -1.573025e-01
       75%
              7.020267e-01 7.184529e-01
                                           8.234454e-01
                                                         7.728197e-01
                                                                       5.172036e-01
              2.163273e+00
                            2.278455e+00
                                           2.134166e+00
                                                         2.818158e+00
                                                                       4.377280e+00
      max
                                 meanfun
                      mode
                                                 minfun
                                                               maxfun
                                                                            meandom
```

```
2.949000e+03 2.949000e+03
                                   2.949000e+03 2.949000e+03 2.949000e+03
count
                                                4.047853e-16 -2.313059e-16
       1.542039e-16 -4.626118e-16
                                   1.734794e-16
mean
std
       1.000170e+00 1.000170e+00
                                   1.000170e+00
                                                 1.000170e+00 1.000170e+00
min
      -2.400750e+00 -2.883410e+00 -1.650307e+00 -4.371693e+00 -1.640394e+00
25%
      -5.784319e-01 -8.087174e-01 -1.099528e+00 -2.241812e-01 -7.924862e-01
50%
                                                 4.519023e-01 -1.262821e-01
       2.465741e-01 -5.629299e-02
                                   6.330205e-01
75%
       7.115593e-01
                    8.220824e-01
                                   6.964096e-01
                                                 6.223510e-01 6.628023e-01
                                                 6.820800e-01 3.823693e+00
max
       1.497922e+00
                     2.817796e+00
                                   4.578770e+00
```

 ${\tt mindom}$ dfrange modindx 2.949000e+03 2.949000e+03 2.949000e+03 count -3.855098e-17 1.252907e-16 -6.264534e-17 mean std 1.000170e+00 1.000170e+00 1.000170e+00 min -7.688267e-01 -4.954654e+00 -1.481178e+00 25% -7.214569e-01 -1.625134e-01 -6.667216e-01 50% -4.688177e-01 3.324077e-01 -2.996157e-01 75% 6.591078e-01 3.557332e-01 2.890998e-01 3.699729e+00 1.531702e+00 4.504475e+00 max

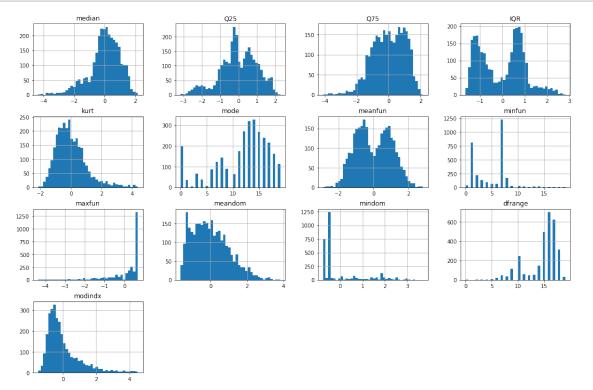
[243]: df_voice_standard.hist(bins = 40, figsize=(18, 12)) plt.show()



4 Dyskretyzacja

Dyskretyzacji używamy dla nieregularnych rozkładów $mode\ i\ dfrange$ aby nasze modele lepiej sobie z nimi radziły.

```
[253]: df_voice_standard.hist(bins = 40, figsize=(18, 12))
plt.show()
```



5 Baseline model

Pierwszy model baselinowy to najprostsza instrukcja warunkowa, na kolumnie "meanfun", w której wartości bardzo ładnie separują się w zależności od targetu. Jak zobaczymy już tak banalny model daje nam trafność na poziomie 95 %.

```
[228]: df_voice_disc['label'] = df_voice[['label']]
df_voice_standard['label'] = df_voice[['label']]
```

```
[229]: def baseline_model(data):
    ## warunek meanfun < 0.13 -> male, otherwise: female
    suma = 0
    for i in range(len(data)):
        if(data["meanfun"][i] < 0.14):
            predicted = 'male'
        else:
            predicted = 'female'
        if(predicted == data['label'][i]):
            suma = suma + 1
        return suma / len(data)</pre>
```

```
[230]: baseline_model(df_voice)
```

[230]: 0.9501525940996948

6 Baseline model x2

Drugi baselinowym modelem będzie regresja logistyczna bez regularyzacji. Trafność modelu to 98 %.

C:\Users\komp\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.8_qbz5n2k
fra8p0\LocalCache\local-packages\Python38\sitepackages\sklearn\utils\validation.py:63: DataConversionWarning: A column-vector
y was passed when a 1d array was expected. Please change the shape of y to
(n_samples,), for example using ravel().
 return f(*args, **kwargs)

[263]: 0.9807909604519774